

What mathematicians
hate the most
about their job?



Automated Correction of Math Assignments

Mirek Olšák and David Stanovský

Charles University, Prague



European Research Council

NextReason

Assumption

- Math education survives as it is (at least 10-20 more years)

Math education: Calculus vs. Real Math

Calculus

(of any sort: differential, integral, matrix, ...)

- algorithmic exercises
- final answer matters most
- WebAssign (etc.) works just fine

Pure math

- we teach proofs, students write full arguments
- grading quality of arguments
- not aware of anything useful

Challenges in grading pure math assignments

- OCR of hand writing
- assessing quality of argumentation (and writing style)
 1. correct / incorrect
 - ... if incorrect, provide feedback for resubmission
 2. evaluation on a scale
 - ... and provide justification

Why interesting for AITP? *A different kind of a challenge.*

classical (auto)formalization:

- text mostly correct
- the few gaps are usually correctable

grading tests:

- text mostly incorrect
- assessment of quality
- hints for improvement / fair partial credit

Experimental system setup:

Linear Algebra class for math students at Charles Uni.

- about 300 students of pure and applied math
- 48 homework problems (proofs or creative computational)
- 5+5 final exams (problems of all sorts, 16 pages), about 1000 tests total per year
- canonical textbook (!)

(6) [20 bodů NMAG112 / 10 bodů NMAG114] V této úloze máte dokázat tvrzení ze skript, lečdy v reformulované nebo méně obecné podobě. V důkazu se neopírejte o obecnější formulaci téhož tvrzení ani o silnější tvrzení. Pokud kromě definic použijete ještě nějaké jiné tvrzení, měla by jeho formulace být součástí důkazu.

- (a) Ať $A = (a_1, \dots, a_n)$ je ortonormální báze komplexního vektorového prostoru V se skalárním součinem $\langle \cdot, \cdot \rangle$ a ať b je vektor z V . Dokažte, že souřadnice vektoru b vzhledem k bázi A jsou $(\langle a_1, b \rangle, \langle a_2, b \rangle, \dots, \langle a_n, b \rangle)^T$.

Protože $b \in V$ platí i.e. $b = x_1 a_1 + \dots + x_m a_m$ pro nějaká $x_1, \dots, x_m \in \mathbb{C}$.
 $\langle a_j, b \rangle = \langle a_j, x_1 a_1 + \dots + x_m a_m \rangle = x_1 \langle a_j, a_1 \rangle + \dots + x_m \langle a_j, a_m \rangle$

Proč? $\langle a_j, a_i \rangle = \delta_{ji}$ pokud $j \neq i$ tak $\langle a_j, a_i \rangle = 0$ protože A je ortonormální, jinak $\langle a_j, a_j \rangle = 1$ pro $\forall i, j \in \{1, \dots, m\}$ a tedy dosadíme $\langle a_j, b \rangle = x_j$.
 $[b]_A = (x_1, \dots, x_m)^T$ a tedy
 $[b]_A = (\langle a_1, b \rangle, \dots, \langle a_m, b \rangle)$

- 2 (b) Dokažte, že unitárně diagonalizovatelné matice jsou normální. Vycházejte pouze z definic.

Mějme matici $A \in \mathbb{C}^{n \times n}$ která je unitárně diagonalizovatelná, tedy $\exists$ báze B kde platí i.e. A je vůči této bázi diagonální. Tedy platí i.e. $A = [id]_B^{-1} [D]_B [id]_B$. Matice $[D]_B$ je normální, protože platí i.e. $D^* D = D D^*$ (D -diagonální) B je unitární báze a kdy i matice $[id]_B^{-1}$ je unitární podle tvrzení o unitárních maticích je i U^* unitární. To znamená, že A je unitárně podobná normální matici, což znamená, že $\exists$ báze B i.e. A je vůči ní diagonální a tedy je normální.

Využíváš tvrzení, že matice, která je unitárně podobná normální matici, je i.e. normální.



- (b) Pouze pro NMAG 112: Lineární operátor f na prostoru

$$V = \text{Span}\{(1, 2, 3, 0)^T, (0, 1, 2, 3)^T\} \subseteq \mathbb{R}^4$$

4 splňuje

$$f((1, 2, 3, 0)^T) = (2, 4, 6, 0)^T, \quad f((0, 1, 2, 3)^T) = (1, 4, 7, 6)^T$$

Spočítejte $f^{42}((x, 2x + y, 3x + 2y, 3y)^T)$ pro všechna $x, y \in \mathbb{R}$. (Připomeňme, že f^{42} značí 42-násobné složení $f \circ f \circ \dots \circ f$.)

$$B = \left(\begin{pmatrix} 1 \\ 2 \\ 3 \\ 0 \end{pmatrix}, \begin{pmatrix} 0 \\ 1 \\ 2 \\ 3 \end{pmatrix} \right) \quad [f]_B = \begin{pmatrix} 2 & 1 \\ 0 & 2 \end{pmatrix}$$

$$[f]_B^{42} = \begin{pmatrix} 2 & 1 \\ 0 & 2 \end{pmatrix}^{42} = \begin{pmatrix} 2^{42} & 2^{41} \cdot 42 \\ 0 & 2^{42} \end{pmatrix}$$

$$s = (x, 2x + y, 3x + 2y, 3y) = b_1 x + b_2 y$$

$$[s]_B = \begin{pmatrix} x \\ y \end{pmatrix}$$

$$[f(s)]_B = \begin{pmatrix} 2^{42} & 2^{41} \cdot 42 \\ 0 & 2^{42} \end{pmatrix} \begin{pmatrix} x \\ y \end{pmatrix} = \begin{pmatrix} x \cdot 2^{42} + 2^{41} \cdot 42 y \\ y \cdot 2^{42} \end{pmatrix}$$

$$[f(s)]_B^{42} = \begin{pmatrix} x \cdot 2^{42} + y \cdot 2^{41} \cdot 42 \\ y \cdot 2^{42} \\ 0 \\ 0 \end{pmatrix}$$

Initial tests: LLM only (*Claude Opus*)

- OCR by Claude
- test assessment by Claude

Results: (grad student assistants: I completely agree with ~85% of credit assignments)

- non-algorithmic computational problems: sort of OK
 - I completely agree: ~60%, mostly agree: ~20%, fail: ~20%
- textbook proofs – identifying correct solutions: quite OK
 - nearly always identifies correct proofs, rarely approves incorrect ones
- textbook proofs - partial credit: unsatisfactory
 - << 50% gradings acceptable

Principal troubles

- *my* failure to explain grading system in sufficient detail
- sloppy reading, failure to trully “understand” the solution
 - accepting subtle but crucial errors
 - incorrect identification of the spot where student went off the road
 - too big partial credit for very incomplete solutions (despite explicit instructions)
- occasionally,
 - unable to recognize twisted logic (reverse implications, ...)
 - hallucinations

Unexpected success: OCR quality seems good (but \$\$ expensive)

Plans for improvement

- A. LLM only, better prompting (specific roadmap, clearer instructions, provide sample solution (?), ...)

- B. LLM + formalization
 - translate to a controlled language
 - linguistic analysis? scoring? ...?
 - how to measure the failure of a proof attempt?

Philosophical question:

Is human math a language problem (thus solvable by a language model), or more?

Conclusions

-?
- We don't want AI to prove our theorems, we want AI to do the boring stuff! 😊